

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO
CENTRO DE CIÊNCIAS EXATAS, NATURAIS E DA SAÚDE
DEPARTAMENTO DE COMPUTAÇÃO
GERENCIAMENTO DE BANCO DE DADOS

KAILANY ALVES SILVA
LUKAS RODRIGUES BASILIO
THIAGO TONELLI DA SILVA

TRABALHO DE INTEGRAÇÃO DE DADOS:
MODELAGEM MULTIDIMENSIONAL E INTEGRAÇÃO DE DADOS
(SUS E IBGE) PARA UM SISTEMA DE APOIO À DECISÃO
SOBRE O TABAGISMO NO BRASIL

ALEGRE - ES

2026

KAILANY ALVES SILVA
LUKAS RODRIGUES BASILIO
THIAGO TONELLI DA SILVA

**TRABALHO DE INTEGRAÇÃO DE DADOS:
MODELAGEM MULTIDIMENSIONAL E INTEGRAÇÃO DE DADOS
(SUS E IBGE) PARA UM SISTEMA DE APOIO À DECISÃO
SOBRE O TABAGISMO NO BRASIL**

Trabalho avaliativo apresentado à Universidade Federal do Espírito Santo - UFES (Centro de Ciências Exatas, Naturais e da Saúde), como requisito parcial para a aprovação na disciplina de Gerenciamento de Banco de Dados.

Professor: Prof. Antonio Almeida de Barros Junior

ALEGRE - ES

2026

SUMÁRIO

1. INTRODUÇÃO.....	4
2. BASES DE DADOS UTILIZADAS.....	5
2.1. Base 1: Sistema de Informações Hospitalares (SIH/SUS).....	5
2.2. Base 2: Estimativas Populacionais Anuais (IBGE).....	5
2.3. Justificativa da Escolha das Bases.....	6
3. REQUISITOS DO SISTEMA DE APOIO À DECISÃO (SAD).....	7
3.1. Necessidades Executivas.....	7
4. MODELO MULTIDIMENSIONAL (DATA MART).....	8
Figura 1 - Diagrama Físico do Modelo Multidimensional Star Schema.....	9
Fonte: Elaborado pelos autores (2026).....	9
5. PROCESSO DE ETL.....	10
5.1 Arquitetura do Pipeline.....	10
Fonte: Elaborado pelos autores (2026).....	11
5.2 Aplicação da Fração Atribuível Populacional (FAP).....	11
6. DASHBOARDS (RELATÓRIOS DE BUSINESS INTELLIGENCE).....	12
6.1 D1 – Visão Geral (Painel Executivo).....	13
Fonte: Elaborado pelos autores (2026).....	13
6.2 D2 – Análise Geográfica.....	14
Fonte: Elaborado pelos autores (2026).....	14
6.3 D3 – Perfil Demográfico.....	15
Fonte: Elaborado pelos autores (2026).....	15
6.4 D4 – Gravidade Clínica.....	16
Fonte: Elaborado pelos autores (2026).....	16
6.5 D5 – Custo Per Capita.....	17
Fonte: Elaborado pelos autores (2026).....	17
6.6 D6 – Tendência Histórica.....	18
Fonte: Elaborado pelos autores (2026).....	18
7. MEDIDAS DAX IMPLEMENTADAS.....	19
7.1 Medidas Base (Volumetria Absoluta).....	19
7.2 Medidas Epidemiológicas Relativas.....	19
7.3 Medidas de Integração (SUS e IBGE).....	20
8. CONSIDERAÇÕES FINAIS.....	21
9. REFERÊNCIAS.....	22

1. INTRODUÇÃO

O tabagismo é reconhecido pela Organização Mundial da Saúde (OMS) como uma das principais causas evitáveis de morte no mundo. No Brasil, as doenças diretamente relacionadas ao consumo de tabaco representam um peso significativo sobre o Sistema Único de Saúde (SUS), tanto em termos de vidas perdidas quanto de recursos financeiros consumidos.

O presente trabalho propõe a construção de um Sistema de Apoio à Decisão (SAD) baseado em técnicas de Business Intelligence (BI) para analisar o impacto financeiro e epidemiológico do tabagismo no Brasil ao longo de 11 anos (2011 a 2021). Para isso, foram integradas duas bases de dados públicas: o Sistema de Informações Hospitalares do SUS (SIH/DATASUS) e as Estimativas Populacionais Anuais por Município do IBGE.

A integração dessas duas fontes heterogêneas em um modelo multidimensional permite responder a perguntas estratégicas de saúde pública que não poderiam ser respondidas isoladamente, tais como: qual o custo per capita do tabagismo para cada município brasileiro e quais estados apresentam as maiores taxas de internação proporcionais à sua população.

2. BASES DE DADOS UTILIZADAS

2.1. Base 1: Sistema de Informações Hospitalares (SIH/SUS)

O Sistema de Informações Hospitalares (SIH) é mantido pelo Departamento de Informática do SUS (DATASUS) e registra todas as internações financiadas pelo sistema público em território nacional. Os dados originais são disponibilizados em um formato governamental compactado e legado (extensão .dbc), separados por estado e por mês.

Para viabilizar o projeto, a extração foi automatizada via FTP utilizando a biblioteca Python PySUS, processando um total de 132 arquivos mensais (abrangendo todos os 27 estados no período de 2011 a 2021). Durante a extração, foi aplicada a técnica de Early Filtering (filtragem antecipada em memória): o script converteu os arquivos para DataFrames do Pandas e isolou exclusivamente os registros cujos diagnósticos (CID-10) pertenciam às doenças catalogadas pela OMS como relacionadas ao tabagismo, descartando o volume massivo de internações não pertinentes antes da carga no banco de dados.

A seleção de quais grupos de diagnósticos (CID-10) deveriam ser incluídos no banco de dados, como cânceres, doenças cardiovasculares e respiratórias crônicas, foi baseada nas metodologias epidemiológicas validadas pelo Instituto Nacional de Câncer (INCA) e pelo estudo de carga do tabagismo no Brasil de Pinto et al. (2015), que serviram como referencial teórico para a modelagem das regras de filtragem do banco de dados deste projeto.

2.2. Base 2: Estimativas Populacionais Anuais (IBGE)

A segunda base de dados fornece a população estimada de cada um dos 5.570 municípios brasileiros, ano a ano, para o período analisado (2011 a 2021). A extração foi realizada de forma automatizada consumindo a API de Dados Agregados (SIDRA) do Instituto Brasileiro de Geografia e Estatística (IBGE) por meio de requisições HTTP utilizando a biblioteca Python requests, que retorna a carga de dados em formato JSON.

A inserção dessa base no Data Mart é o coração matemático do Sistema de Apoio à Decisão (SAD), pois ela atua como o denominador comum para as medidas epidemiológicas. Sem o número exato de habitantes por ano, seria impossível calcular indicadores relativos padronizados, como a Taxa de Internação (por 100 mil habitantes) e o Custo Per Capita, que são as métricas oficiais para medir o real impacto de uma doença eliminando distorções de densidade demográfica entre os estados.

2.3. Justificativa da Escolha das Bases

Durante a fase de engenharia de requisitos, cogitou-se utilizar a Pesquisa Nacional de Saúde (PNS) do IBGE como base secundária para o cruzamento com os dados do SUS. Entretanto, a PNS foi tecnicamente descartada para a modelagem multidimensional proposta por três limitações estruturais:

- **Falta de Histórico Contínuo:** A pesquisa ocorreu apenas nos anos de 2013 e 2019. Como os requisitos do trabalho exigem uma série histórica contínua de no mínimo 10 anos, a PNS inviabilizaria a análise de tendência temporal (ano a ano) construída no Data Mart.
- **Granularidade Geográfica Incompatível:** Por ser uma pesquisa fundamentada em amostragem populacional, a PNS não possui precisão estatística ou detalhamento para a totalidade dos 5.570 municípios brasileiros, o que mataria o requisito de mapas e análises regionais granulares.
- **Ausência de Denominador Comum:** A PNS mapeia a "prevalência" (ex: percentual de fumantes), mas a matemática para se calcular o Impacto Epidemiológico e Financeiro exige a "População Total Absoluta" como denominador de divisão das métricas de internação.

Dessa forma, as Estimativas Populacionais Anuais substituíram a PNS com perfeição, pois fornecem uma matriz contínua de Tempo (2011 a 2021) e Espaço (todos os municípios), garantindo o cálculo perfeito das taxas epidemiológicas e geográficas no banco de dados.

3. REQUISITOS DO SISTEMA DE APOIO À DECISÃO (SAD)

A construção de um Sistema de Apoio à Decisão (SAD) eficiente exige que a modelagem dos dados não seja feita baseada apenas nas colunas disponíveis nas fontes originais, mas sim orientada a responder a perguntas estratégicas de negócio. No contexto da saúde pública, essas perguntas são chamadas de Necessidades Executivas, pois representam as métricas que um gestor do Ministério da Saúde ou um pesquisador precisaria ter em mãos para direcionar políticas públicas antitabagismo.

3.1. Necessidades Executivas

A partir do escopo do projeto, foram mapeadas as seguintes necessidades executivas que o sistema deve ser capaz de responder dinamicamente:

NE01: Conhecer o custo total atribuível ao tabagismo financiado pelo SUS na última década.

NE02: Identificar o volume absoluto de internações e óbitos hospitalares causados pelas doenças do tabaco.

NE03: Calcular a taxa de mortalidade por 100 mil habitantes, visando eliminar distorções de análise causadas pela densidade demográfica.

NE04: Identificar geograficamente quais estados e municípios apresentam as maiores taxas de internação relativas.

NE05: Traçar o perfil demográfico do paciente típico, cruzando recortes de sexo, raça/cor e faixa etária.

NE06: Ranquear as doenças relacionadas ao tabaco por nível de severidade clínica (letalidade) e custo médio.

NE07: Calcular o custo per capita por habitante, realizando o cruzamento matemático entre os gastos do SUS e a população oficial do IBGE.


4. MODELO MULTIDIMENSIONAL (DATA MART)

O Data Mart foi estruturado e implementado no Sistema Gerenciador de Banco de Dados (SGBD) PostgreSQL. Diferente de bancos de dados transacionais (OLTP) que visam a normalização para inserções rápidas, a arquitetura deste projeto adotou a modelagem multidimensional no formato Star Schema (Esquema Estrela), cujo objetivo é a desnormalização estratégica focada no altíssimo desempenho de leitura por ferramentas de Business Intelligence.

Uma das principais decisões de arquitetura foi a implementação de Surrogate Keys (SKs) autoincrementais do tipo inteiro em todas as Tabelas Dimensão. Isso garante o isolamento do Data Mart em relação a possíveis mudanças nas chaves naturais de negócio (códigos governamentais), mantendo a integridade referencial intacta ao longo das consolidações temporais.

O modelo resultante caracteriza-se pela presença de duas Tabelas Fato conectadas às dimensões, conforme ilustrado na Figura 1: a `f_internacao` (que armazena a volumetria e os custos hospitalares do SUS) e a `f_populacao` (que armazena os dados demográficos do IBGE). Essa modelagem permite que o Power BI cruze métricas financeiras com dados populacionais de forma transparente, utilizando as dimensões compartilhadas de Calendário e Localidade.

Figura 1 - Diagrama Físico do Modelo Multidimensional Star Schema.



Fonte: Elaborado pelos autores (2026).

5. PROCESSO DE ETL


5.1 Arquitetura do Pipeline

Para garantir a integridade, escalabilidade e a reprodutibilidade da pesquisa, o processo de ETL (Extração, Transformação e Carga) foi desenvolvido inteiramente na linguagem de programação Python, eliminando a necessidade de intervenção manual no tratamento das bases de dados.

O pipeline foi projetado utilizando uma arquitetura de múltiplos estágios, inspirada nos conceitos modernos de engenharia de dados (transição de uma camada de dados brutos para dados refinados). Essa separação em camadas lógicas — uma área de Staging (funcionando como um Data Lake relacional transitório) e uma área definitiva de Data Warehouse — garante que os dados sujos sejam isolados antes que as regras rigorosas de modelagem dimensional sejam aplicadas.

A Figura 2 ilustra o fluxo arquitetural completo do sistema, desde a captura dos dados nos órgãos governamentais (DATASUS e IBGE) até a disponibilização para a ferramenta de Business Intelligence.

Figura 2 - Arquitetura do Pipeline de ETL



Fonte: Elaborado pelos autores (2026).

5.2 Aplicação da Fração Atribuível Popacional (FAP)

Durante o estágio de Transformação no pipeline de ETL (antes da carga final no PostgreSQL), aplicou-se a regra de negócio central do projeto: o cálculo do impacto real do tabagismo. Conforme os referenciais teóricos de Pinto et al. (2015) e INCA (2020), apenas uma porcentagem específica de cada doença é estatisticamente causada pelo uso do cigarro (Fração Atribuível).

Dessa forma, o cálculo estático de multiplicação do FAP foi executado diretamente no script Python linha a linha. Se uma internação por câncer custou R\$10.000,00 e o FAP da doença é de 35 o custo real da internação relacionada a doença será de R\$3.500,00. Isso garante que o Data Mart contenha informações rigorosamente relativas ao tabaco, aliviando a ferramenta de BI de realizar cálculos complexos em milhões de linhas.

6. DASHBOARDS (RELATÓRIOS DE BUSINESS INTELLIGENCE)


Como camada de visualização do Sistema de Apoio à Decisão (SAD), foram desenvolvidos 6 painéis interativos utilizando a ferramenta Microsoft Power BI. O software foi conectado diretamente ao Data Mart no PostgreSQL via conector nativo relacional. A navegação entre os painéis foi estruturada de forma narrativa, partindo de uma visão executiva agregada (macro) até o detalhamento individual por doença e município (micro).

Destaca-se o comportamento interativo e matemático do modelo: por padrão, quando nenhum filtro temporal está selecionado, os visuais consolidam a carga completa de 11 anos, exibindo médias da década para as taxas epidemiológicas e custos per capita (utilizando a média populacional do período como denominador). Entretanto, graças à inteligência das medidas DAX e ao relacionamento do Star Schema, ao se aplicar um filtro na dimensão Tempo (ex: Ano de 2019), o sistema abandona o comportamento de média histórica e recalcula instantaneamente o resultado real daquele ano, dividindo os custos e internações exatos de 2019 pela população exata aferida pelo IBGE em 2019.

6.1 D1 – Visão Geral (Painel Executivo)

Este painel responde à pergunta central: "O que está acontecendo no Brasil?". Ele atua como um resumo executivo, evidenciando de forma agregada e em números absolutos o impacto financeiro (custo total atribuível), o volume de internações e o total de óbitos gerados pelas doenças do tabaco no SUS, além de ranquear as doenças que mais consomem orçamento público.

Figura 3 - Dashboard D1: Visão Geral e Impacto Orçamentário




Fonte: Elaborado pelos autores (2026).

6.2 D2 – Análise Geográfica

Este painel responde à pergunta: "Onde a situação é mais crítica?". Seu principal objetivo é eliminar o viés populacional das análises geográficas. Ao exibir o mapa do país através da métrica de Taxa de Internação por 100 mil habitantes, ele revela quais estados e regiões sofrem proporcionalmente mais com o tabagismo, independentemente do seu tamanho populacional bruto.

Figura 4 - Dashboard D2: Mapa de Risco e Taxas Relativas por UF




Fonte: Elaborado pelos autores (2026).

6.3 D3 – Perfil Demográfico

O terceiro painel responde à pergunta: "Quem é a principal vítima do tabagismo no SUS?". Ele traça a persona do paciente típico cruzando as métricas hospitalares com a dimensão demográfica, identificando a predominância de internações e óbitos de acordo com o sexo, faixa etária e a declaração de raça/cor.

Figura 5 - Dashboard D3: Perfil Étnico, Etário e de Sexo do Paciente




Fonte: Elaborado pelos autores (2026).

6.4 D4 – Gravidade Clínica

Com foco na dimensão das doenças, este relatório responde: "Quão grave é cada complicação gerada pelo tabaco?". O painel estabelece um ranking clínico focado na severidade, evidenciando a taxa de letalidade (risco de óbito), o tempo médio de ocupação de leitos e o custo individual médio de cada enfermidade.

Figura 6 - Dashboard D4: Letalidade e Tempo de Permanência




Fonte: Elaborado pelos autores (2026).

6.5 D5 – Custo Per Capita

Este painel responde à pergunta do cidadão comum: "Quanto o contribuinte paga indiretamente por esse problema?". Ele evidencia a eficiência da modelagem de dados ao cruzar financeiramente o SUS com o IBGE. O resultado é o cálculo do custo per capita do tabagismo, permitindo uma auditoria de gastos detalhada ao nível municipal.

Figura 7 - Dashboard D5: Cruzamento de Custos e População (Per Capita)




Fonte: Elaborado pelos autores (2026).

6.6 D6 – Tendência Histórica

O último relatório responde: "Para onde estamos indo?". Ele traça as curvas de evolução temporal das internações, custos e mortalidade ao longo da década analisada. O painel é fundamental para verificar tendências de crescimento, avaliar os impactos sistêmicos causados pela pandemia de COVID-19 no sistema hospitalar e projetar cenários futuros.

Figura 8 - Dashboard D6: Evolução Temporal da Década



Fonte: Elaborado pelos autores (2026).

7. MEDIDAS DAX IMPLEMENTADAS

Uma das premissas de um Sistema de Apoio à Decisão (SAD) robusto é a separação de responsabilidades. Enquanto os cálculos estáticos em nível de linha (como a aplicação da porcentagem do FAP) foram delegados e consolidados no banco de dados (ETL), as agregações dinâmicas que exigem adaptação aos filtros de tempo e espaço não devem residir em colunas fixas do PostgreSQL, mas sim na camada semântica da ferramenta de visualização.

Para garantir que cálculos complexos (como Taxas Relativas e Custos Per Capita) recalculam instantaneamente quando o usuário filtra um ano ou município específico, toda a matemática agregada do projeto foi programada em DAX (Data Analysis Expressions). As 10 medidas abaixo compõem o núcleo analítico do projeto.

7.1 Medidas Base (Volumetria Absoluta)

São os cálculos de fundação que somam os dados brutos da Tabela Fato.

- Total de Internações: Soma simples de todos os registros de entrada. Total de Internacoes = $\text{SUM}(\text{f_internacao}[\text{qt_internacoes}])$
- Total de Mortes: Soma das mortes registradas nas altas hospitalares. Total de Mortes = $\text{SUM}(\text{f_internacao}[\text{qt_mortes}])$
- Custo Atribuível: Agregação do valor financeiro real da doença (já com o FAP aplicado). Custo Atribuivel = $\text{SUM}(\text{f_internacao}[\text{vl_total}])$

7.2 Medidas Epidemiológicas Relativas

Indicadores de eficiência médica e gravidade, cruzando as medidas base.

- Taxa de Letalidade: Indica o risco percentual de morte da doença. Taxa de Letalidade = $\text{DIVIDE}([\text{Total de Mortes}], [\text{Total de Internacoes}]) * 100$
- Custo Médio por Internação: Revela o custo individual médio de cada doença. Custo Medio por Internacao = $\text{DIVIDE}([\text{Custo Atribuivel}], [\text{Total de Internacoes}])$
- Média Dias Permanência: Impacto da doença no giro de leitos hospitalares. Media Dias Permanencia = $\text{DIVIDE}(\text{SUM}(\text{f_internacao}[\text{qt_dias_permanencia}]), [\text{Total de Internacoes}])$

7.3 Medidas de Integração (SUS e IBGE)

Estas cruzam os valores do SUS com o denominador de População (IBGE), ajustando-se ao filtro de Ano e Município.

- População Média: Captura a estimativa do IBGE. Como os dados podem estar granulados por mês, divide-se a soma anual por 12 para encontrar a população real do período. $\text{Populacao Media} = \text{SUM}(f_populacao[nu_populacao_estimada]) / 12$
- Taxa de Internação por 100k: Nível de internações proporcionais a cada 100 mil habitantes. $\text{Taxa de Internacao por 100k} = \text{DIVIDE}([\text{Total de Internacoes}], [\text{Populacao Media}]) * 100000$
- Taxa de Mortalidade por 100k: Nível de óbitos proporcionais a cada 100 mil habitantes. $\text{Taxa de Mortalidade por 100k} = \text{DIVIDE}([\text{Total de Mortes}], [\text{Populacao Media}]) * 100000$
- Custo Per Capita: Descobre quanto o impacto custa anualmente para cada cidadão. $\text{Custo Per Capita} = \text{DIVIDE}([\text{Custo Atribuivel}], [\text{Populacao Media}])$

8. CONSIDERAÇÕES FINAIS

A construção deste Sistema de Apoio à Decisão (SAD) demonstrou na prática o imenso potencial das técnicas de Business Intelligence e Engenharia de Dados quando aplicadas à gestão da saúde pública. A integração do Sistema de Informações Hospitalares (SIH/DATASUS) com as Estimativas Populacionais do IBGE revelou-se um desafio arquitetural superado através do uso de ferramentas open-source (Python, PostgreSQL) e modelagem dimensional (Star Schema).

A adoção de uma arquitetura de múltiplos estágios (ETL) provou ser fundamental para isolar as regras complexas de negócio, como o cálculo estático da Fração Atribuível Populacional (FAP), da camada de visualização. Essa separação garantiu que os 6 dashboards interativos apresentassem alta performance de leitura e processassem o período de 11 anos de dados com cálculos epidemiológicos instantâneos na linguagem DAX.

Por fim, os resultados analíticos alcançados confirmam a necessidade urgente de políticas públicas contínuas de combate ao tabagismo. O painel evidenciou um custo de bilhões aos cofres públicos e um número alarmante de óbitos, concentrados principalmente em diagnósticos severos como o Câncer de Pulmão.

9. REFERÊNCIAS

BRASIL. Ministério da Saúde. Departamento de Informática do SUS (DATASUS). Sistema de Informações Hospitalares do SUS (SIH/SUS). Disponível em: <http://datasus.saude.gov.br>. Acesso em: jun. 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Estimativas de População. Sistema IBGE de Recuperação Automática (SIDRA). Disponível em: <https://sidra.ibge.gov.br>. Acesso em: jun. 2026.

INSTITUTO NACIONAL DE CÂNCER JOSÉ ALENCAR GOMES DA SILVA (INCA). Carga de doença atribuível ao uso do tabaco no Brasil e potencial impacto do aumento de preços por meio de impostos. Rio de Janeiro: INCA, 2020.

PINTO, M. T. et al. Carga do tabagismo no Brasil e benefício potencial do aumento de impostos sobre os cigarros para a economia e para a redução de mortes e adoecimento. Cadernos de Saúde Pública, v. 31, p. 1291-1302, 2015.